


Vue d'ensemble



Résumé automatique

Le dataset contient 891 lignes et 12 colonnes. Il comprend 7 colonnes numériques et 5 colonnes catégorielles. Le taux de valeurs manquantes est de 8.1%. La colonne 'Age' présente 19.9% de valeurs manquantes. Score de qualité global: 89.34/100 (Grade B) La meilleure corrélation avec 'Survived' est 'Pclass' (r=0.34) Action prioritaire: Supprimer la colonne 'Cabin'

Détection ML



Valeurs manquantes


Colonne	Manquants	%
Age	177	19.87%
Cabin	687	77.1%
Embarked	2	0.22%

Alertes

- Colonnes identifiant : PassengerId, Name
- Forte asymétrie : SibSp, Parch, Fare


Corrélations

Matrice de corrélation (Pearson)




Histogrammes

Distributions des variables numériques



Boxplots

Boxplots des variables numériques



▣ Tests de normalité

ColonneP-valueDistributionRecommandation

▣▣ Outliers

Colonne	Outliers (IQR)	%	Action
Age	11	1.54%	Acceptable
SibSp	46	5.16%	Acceptable
Parch	213	23.91%	Traitement recommandé
Fare	116	13.02%	Traitement recommandé

▣ Modèles recommandés

- Logistic Regression (baseline)
- Random Forest Classifier
- XGBoost Classifier
- LightGBM Classifier
- Support Vector Machine (SVM)

▣ Plan d'action

Priorité	Action	Raison
Basse	Supprimer la colonne 'Cabin'	77.1% de valeurs manquantes
Basse	Considérer 'PassengerId' comme identifiant	Valeurs uniques sur chaque ligne
Basse	Considérer 'Name' comme identifiant	Valeurs uniques sur chaque ligne

▣ Synthèse finale

3

Colonnes à nettoyer

4

Colonnes outliers

7

Non-normales

89.34/100

Score qualité